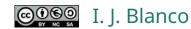




## Big Data I

Máster Universitario en Ciencia de Datos e Ingeniería de Computadores

Consulta estructurada sobre datos no estructurados masivos: Apache® Impala



Departamento de Ciencias de la Computación e Inteligencia Artificial http://decsai.ugr.es



- Infraestructura para DataWarehousing basada en Hadoop.
- Permite:
  - extraer resúmenes de datos,
  - consultas ad hoc y
  - analizar grandes volúmenes de datos
- Es útil para grandes volúmenes de datos que no cambian.





- Es un lenguaje de consulta sobre flujos de datos.
- Permite al usuario especificar qué desea obtener del flujo de datos (lenguaje de 4ª generación) y no necesita decir cómo.
- Útil para ETL y para usuarios habituales de SQL o herramientas de *Bussiness Intelligence*.
- filtrado, agregación, cálculo u ordenación son cosa del motor Impala.



 Hadoop: sistema de proceso por lotes gasta tiempo en organizar el trabajo.



- Las consultas en Impala sobre conjuntos de datos pequeños (pocos 10<sup>2</sup> MB) son muy lentas.
- No es útil para OLTP.
- No sirve para consultas en tiempo real.
- No es nada eficiente para realizar *updates* a nivel de fila (tupla).



```
package org.myorg;
import java.io.IOException;
import java.util.*;
import org.apache.hadoop.fs.Path;
import org.apache.hadoop.conf.*;
import org.apache.hadoop.io.*;
import org.apache.hadoop.mapreduce.*;
import org.apache.hadoop.mapreduce.lib.input.FileInputFormat;
import org.apache.hadoop.mapreduce.lib.input.TextInputFormat;
import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat;
import org.apache.hadoop.mapreduce.lib.output.TextOutputFormat;
public class WordCount {
 public static class Map extends Mapper<LongWritable, Text, Text, IntWritable> {
    private final static IntWritable one = new IntWritable(1);
    private Text word = new Text();
    public void map(LongWritable key, Text value, Context context) throws IOException, InterruptedException
       String line = value.toString();
       StringTokenizer tokenizer = new StringTokenizer(line);
       while (tokenizer.hasMoreTokens()) {
            word.set(tokenizer.nextToken());
            context.write(word, one);
```

Departamento de Ciencias de la Computación e Inteligencia Artificial - Universidad de Granada



```
public static class Reduce extends Reducer<Text, IntWritable, Text, IntWritable> {
   public void reduce(Text key, Iterable<IntWritable> values, Context context)
     throws IOException, InterruptedException {
       int sum = 0;
      for (IntWritable val : values) {
           sum += val.get();
      context.write(key, new IntWritable(sum));
}
public static void main(String[] args) throws Exception {
   Configuration conf = new Configuration();
       Job job = new Job(conf, "wordcount");
   job.setOutputKeyClass(Text.class);
   job.setOutputValueClass(IntWritable.class);
   job.setMapperClass(Map.class);
   job.setReducerClass(Reduce.class);
   job.setInputFormatClass(TextInputFormat.class);
   job.setOutputFormatClass(TextOutputFormat.class);
   FileInputFormat.addInputPath(job, new Path(args[0]));
   FileOutputFormat.setOutputPath(job, new Path(args[1]));
   job.waitForCompletion(true);
```

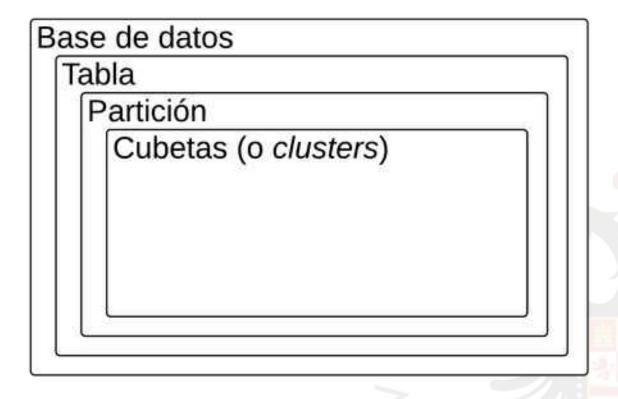




```
CREATE TABLE docs (line STRING);
LOAD DATA INPATH 'docs' OVERWRITE INTO TABLE
docs;
CREATE TABLE word_counts AS
 SELECT word, count(1) AS count FROM
    (SELECT explode(split(line, '\s')) AS
       word FROM docs) w
 GROUP BY word
 ORDER BY word;
```









#### Base de Datos:

- Constituye un namespace (el conjunto de datos para un problema específico)
- Se permiten los mismos nombres de tablas en distintas bases de datos



#### Base de Datos

#### Tabla:

 Unidades de datos homogéneas que comparten esquema (estructura)



#### Base de Datos

#### Tabla

#### Partición:

- Se pueden usar para especificar dónde al macenar los datos en base a valores de clave
- Permiten hacer división lógica de los datos en base a valores de clave (identificación de filas)



#### Base de Datos

#### Tabla

#### Partición

### Cubeta (o cluster):

 Se pueden dividir los datos en función de el valor hash de una columna dada, aparte de la de la partición.



- Tablas gestionadas o internas:
  - se mueven dentro del almacenamiento de Impala,
  - pueden particionarse.
- Tablas externas:
  - se usan desde fuera del almacenamiento, permitiendo a otras aplicaciones acceder a ellas,
  - pueden estar particionadas.





```
CREATE TABLE [IF NOT EXISTS]
[db_name.]table_name
[(col_name data_type [COMMENT
'col_comment'], ...)]
[COMMENT 'table_comment']
[PARTITIONED BY (col_namedata_type
[COMMENT 'col_comment'], ...)]
    [ROW FORMAT row_format]
[STORED AS file_format]
[LOCATION 'hdfs_path']
```



- TINYINT (1 B)
- SMALLINT (2B)
- INT (4 B)
- BIGINT (8 B)
- BOOLEAN
- FLOAT
- DOUBLE
- STRING
- TIMESTAMP

Departamento de Ciencias de la Computación e Inteligencia Artificial - Universidad de Granada

BINARY



- **TINYINT**: -128 .. 127 (no UNSIGNED)
- **SMALLINT**: -32768 .. 32767 (no UNSIGNED)
- **INT**: -2147483648 .. 2147483647
- **BIGINT**: -9223372036854775808 .. 9223372036854775807 (no UNSIGNED)
- BOOLEAN
- **FLOAT**: 1.40129846432481707e-45 .. 3.40282346638528860e+38 (positivos y negativos)
- DOUBLE: 4.94065645841246544e-324 .. 1.79769313486231570e+308 (positivos y negativos)
- **STRING**: hasta 32,767 bytes
- TIMESTAMP: desde el 1-1-1400 hasta el 31-12-9999



```
DELIMITED

[FIELDS TERMINATED BY 'char'

[ESCAPED BY 'char']]

[LINES TERMINATED BY 'char']
```



```
CREATE EXTERNAL TABLE [IF NOT EXISTS]
[db_name.]table_name
[(col_name data_type [COMMENT 'col_comment'], ...)]
[COMMENT 'table_comment']
[PARTITIONED BY (col_namedata_type [COMMENT
'col_comment'], ...)]
    [ROW FORMAT row_format]
[STORED AS file_format]
[LOCATION 'hdfs_path']
```



Creación mediante:

```
CREATE EXTERNAL TABLE grados (<column description>, ...)
ROW FORMAT DELIMITED FIELDS TERMINATED BY ',' LINES TERMINATED BY '\n' LOCATION
'/user/stark/datasets/grado.csv';
```



#### • STRUCT:

STRUCT<calle:STRING,numero:TINYINT,
puerta:STRING,ciudad:STRING,cp:STRING>

MAP:

MAP<STRING,FLOAT>

ARRAY:

ARRAY<STRING>





- Modificación de tablas (ALTER TABLE):
  - para renombrar tablas,
  - para re-ubicar tablas y
  - para particionar tablas no particionadas.
- Borrado de tablas (DROP TABLE): 📮
  - borra los metadatos de la tabla
  - pero no borra datos de tablas externas.
- Ver la estructura de las tablas:
  - SHOW TABLES;
  - DESCRIBE [FORMATTED] <table\_name>;



- Introducir registros en una tabla interna:
  - INSERT [OVERWRITE | INTO]
     <table\_name> VALUES ...
  - INSERT [OVERWRITE | INTO]
     <table\_name> SELECT ...



- Inicia la máquina virtual.
- Hay dos cuentas relevantes en el sistema operativo:
  - Username: root
     Para acceder, abre una ventana de terminal y ejecuta la orden "sudo bash"
  - Username: impala
     Para acceder, abre una ventana de terminal y ejecuta la orden "sudo bash" seguida de "su impala"
     El comando whoami te permitirá saber qué usuario está ejecutando la shell en cada momento.



- Abre una terminal con el usuario impala.
- Comprueba que el fichero de datos
   BX-BooksCorrected.txt está disponible y accesible:

ls /var/tmp/materialImpala

• Si no está disponible, crea el directorio con:

mkdir /var/tmp/materialImpala

y usa el navegador para descargar el fichero dentro del mismo pulsando el enlace:

https://sl.ugr.es/matImpala2



 Crea el directorio para los ficheros de ingesta de datos;

hdfs dfs -mkdir /user/impala/input

Cargar los datos del fichero:



hdfs dfs -put /var/tmp/materialImpala/BX-BooksCorrected.txt /user/impala/input



 Comprobar que el fichero se ha cargado en HDFS:

hdfs dfs -ls /user/impala/input

Acceder a Impala:

impala-shell



## CREATE DATABASE IF NOT EXISTS <dbname>;

- Hay que tener acceso de escritura al directorio en el que se creará la base de datos.
- Como el HDFS está compartido con otras partes del curso, crearemos la DB en un directorio específico:

```
CREATE DATABASE IF NOT EXISTS <dbname>
LOCATION '/user/impala/impalastore.db';
```



- SHOW DATABASES;
- DESCRIBE DATABASE <dbname>;
- USE <dbname>;





Crear una tabla:

CREATE TABLE IF NOT EXISTS BookData (ISBN STRING, BookTitle STRING, BookAuthor STRING, YearOfPublication INT, Publisher STRING) ROW FORMAT DELIMITED FIELDS TERMINATED BY '\;' STORED AS TEXTFILE;

- Comprobar que la tabla se ha creado correctamente:
   DESCRIBE BookData;
- Cargar datos en la tabla:

LOAD DATA INPATH '/user/impala/input/BX-BooksCorrected.txt' OVERWRITE INTO TABLE BookData;



 Consulta 0: obtener el número de libros por cada año

SELECT YearOfPublication, COUNT(BookTitle) FROM BookData GROUP BY YearOfPublication;

 Discutid por grupos como se resolvería esta consulta en cada nodo (mappers) y cómo se combinarían los resultados (reducers).



- Una tabla interna se puede particionar, lo que significa que los registros se dividen en varios flujos en función de que tengan valores iguales en uno o varios atributos.
- Para crear una tabla particionada según un atributo específico:

CREATE TABLE IF NOT EXISTS BookDataPerYear (ISBN STRING, BookTitle STRING, BookAuthor STRING, Publisher STRING) PARTITIONED BY (YearOfPublication INT) ROW FORMAT DELIMITED FIELDS TERMINATED BY '\;' STORED AS TEXTFILE;



 Volcar datos a la tabla particionada desde la tabla sin partición:

INSERT OVERWRITE TABLE BookDataPerYear
PARTITION (yearofpublication = 2003)
SELECT ISBN, BookTitle, BookAuthor,
Publisher FROM BookData WHERE
yearofpublication = 2003;



# Inserción de registros por particiones:

```
PARTITION (yearofpublication = 2004)
    SELECT ISBN, BookTitle, BookAuthor, Publisher FROM BookData WHERE
    yearofpublication = 2004;
INSERT OVERWRITE TABLE BookDataPerYear
   PARTITION (yearofpublication = 2005)
    SELECT ISBN, BookTitle, BookAuthor, Publisher FROM BookData WHERE
    vearofpublication = 2005;
INSERT OVERWRITE TABLE BookDataPerYear
   PARTITION (yearofpublication = 2006)
    SELECT ISBN, BookTitle, BookAuthor, Publisher FROM BookData WHERE
    yearofpublication = 2006;
INSERT OVERWRITE TABLE BookDataPerYear
   PARTITION (yearofpublication = 2007)
    SELECT ISBN, BookTitle, BookAuthor, Publisher FROM BookData WHERE
   yearofpublication = 2007;
```

INSERT OVERWRITE TABLE BookDataPerYear



Los datos en las tablas BookData y
 BookDataPerYear para los años que están entre
 los años de publicación 2003 y 2007 deben ser los
 mismos. ¡Compruébalo!



SELECT YearOfPublication,
COUNT(BookTitle) FROM BookData WHERE
YearOfPublication BETWEEN 2003 AND 2007
GROUP BY YearOfPublication;

SELECT YearOfPublication, COUNT(BookTitle) FROM BookDataPerYear WHERE YearOfPublication BETWEEN 2003 AND 2007 GROUP BY YearOfPublication;



SELECT COUNT(1) FROM (SELECT \* FROM BookDataPerYear WHERE YearOfPublication BETWEEN 2003 AND 2007) bdpy LEFT SEMI JOIN (SELECT \* FROM BookData WHERE YearOfPublication BETWEEN 2003 AND 2007) bd ON bdpy.ISBN = bd.ISBN;

Resultado: 20247 tuplas

©©© I. J. Bl



- Consultar cuántos libros fueron publicados "en el año 0":
   SELECT COUNT(1) FROM BookData WHERE YearOfPublication = 0;
- Limpiar la tabla BookData para quitar los libros del año 0:

```
INSERT OVERWRITE TABLE BookData
   SELECT BookData.* FROM BookData WHERE
   YearOfPublication > 0;
```

• ... y comprobamos:



 Consultar el número de libros de cada autor, en la misma editorial y cada año:

SELECT Publisher, BookAuthor,
 YearOfPublication, COUNT(BookTitle) FROM
 BookData GROUP BY Publisher, BookAuthor,
 YearOfPublication;